Project: 영어 영화감상평에 대한 감성분석 모델 개발

- 전반적인 내용은 다음 페이지부터 설명을 함.
- 과제에서 수행할 사항:
 - 빈 곳을 채워서 프로그램을 완성한다.
 - 실험을 통하여 가장 성능이 잘 나오는 epoch 를 찾는다.
 - 이 관찰에 기반하여 number of epochs 를 변경한다.
 - test 단계를 위한 code를 넣는다.
 - training 의 마지막 epoch 후의 loss 및 validation accuracy 에 대한 출력이 나오는 실행창을 캡쳐하여 보고서에 넣는다.
 - test 단계에서 측정한 test accuracy 의 출력이 나오는 실행창을 캡쳐하여 보고서에 넣는다.
- 제출물: 프로그램(.py 포멧), 결과보고서(.pdf 포멧).
 - project 디렉토리를 압축하여 제출하지 말 것.
 - 위 두 파일만 압축하지 않고 업로드 할 것.

Sentiment analysis (감성분석) 시스템 개발

- 목표: 감성분석
 - Sentiment analysis
- 이는 문서 또는 텍스트 분류의 대표적인 문제임
 - text (document) classification Supervised Learning, ()
- 우리의 방법:
 - BERT 를 사용하는 deep learning 모델 이용

```
Pre-Trained 가 Fine-Tuning
```

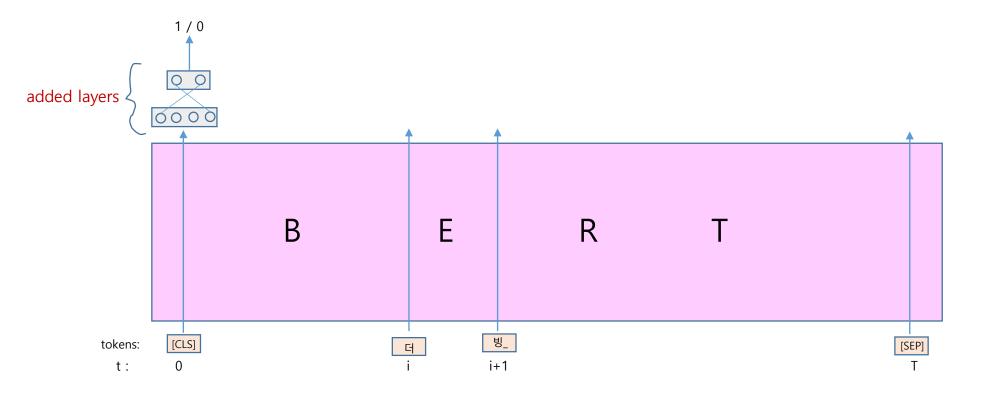
- 학습데이터:
 - 영어로 작성된 영화 감상평 (movie review)
- 본 과제에서 사용할 딥러닝 라이브러리: PYTORCH
- 우리는 English 에 대하여 pretrained 된 BERT 모델인 "bert-base-uncased" 를 사용함.

2018 google BERT

- 사용할 BERT 모델은 Hugging Face 사가 제공하는 transformers 패키지 안에 있는 AutoModel을 사용한다.
- 토크나이져(tokenizer)로는 역시 transformers 안에 있는 AutoTokenizer 를 이용한다
- 이를 위해 transformers 를 설치해야 한다:
 - "pip install transformers" 명령을 이용한다.

모델구성

- BERT 위에 FF 층을 올림.
- FF 층들과 BERT 사이에 LSTM 층을 넣을 수도 있음.
 - 보통 성능이 올라갈 것으로 예상됨.
- [CLS] 토큰을 input token sequence 의 첫 토큰으로 넣음.
- [CLS] 토큰이 입력되는 t=0 의 출력만을 분류 예측(prediction)에 이용함.
 - t=1~T 의 나머지 시간대의 출력들은 이용하지 않음. 즉 loss 의 결정과 prediction 에 이용되지 않음.



```
import numpy as np
import torch
from torch.utils.data import (DataLoader, RandomSampler, SequentialSampler,
                              TensorDataset)
from torch.utils.data.distributed import DistributedSampler
from tgdm import tgdm, trange
from torch import nn
import torch.nn.functional as F
import torch.optim
from torch.utils.data import Dataset, DataLoader
import time
from sklearn.metrics import classification report
from torch.utils.data import TensorDataset, DataLoader, RandomSampler, SequentialSampler
from transformers import AutoModel, AutoTokenizer
```

Tokenizer 와 BERT model 객체 생성

• Pretrained BERT, tokenizer 객체 만들기

```
tokenizer = AutoTokenizer.from_pretrained("bert-base-uncased")
bert = AutoModel.from_pretrained("bert-base-uncased")
```

• GPU 계산장치 준비 (아래를 수정하여 device로 cpu 도 가능하게 할 것!)

```
device = torch.device("cuda")
```

• 상수 설정

```
batch_size = 8
best_acc = 0.0 # 초기값
num_epochs = 5
max_seq_leng = 256
```

Annotated 학습데이터

- 영화감상평에 긍정(1), 부정(0) 레이블을 tagging 한 labeled corpus
 - 첫 줄: comment
 - 각 줄은 3 개의 field이고 이들은 '\t' 로 구분되어 있음
 - id 필드는 무시; document 필드에 감상평; label 필드의 1은 긍정, 0 은 부정을 나타냄.
 - Number of classes = 2.
- 화일명: "train_data_movie_reviews_imdb.txt"
 - 각 줄에 정답레이블(1:긍정/0:부정) 과 영화감상평이 있다.
 - 둘사와는 '\t' 로 구분된다.
 - 25,000 개의 감상평을 가짐 (이는 IMDB 데이터의 일부만 가져온 것임.)

Bromwell High is a cartoon comedy. It ran at the same time as some other programs about school life, Story of a man who has unnatural feelings for a pig. Starts out with a opening scene that is a terrif Homelessness (or Houselessness as George Carlin stated) has been an issue for years but never a plan Airport '77 starts as a brand new luxury 747 plane is loaded up with valuable paintings & such belong Brilliant over-acting by Lesley Ann Warren. Best dramatic hobo lady I have ever seen, and love scenes This film lacked something I couldn't put my finger on at first: charisma on the part of the leading This is easily the most underrated film inn the Brooks cannon. Sure, its flawed. It does not give a party everyone,,, I know this is supposed to be an "art" film,, but wow, they should have handed out This is not the typical Mel Brooks film. It was much less slapstick than most of his movies and actual When I was little my parents took me along to the theater to see Interiors. It was one of many movies

Training example 준비

- 한 감상평 text 에 대하여 하나의 훈련예제를 만들어야 함:
 - 1) Input token sequence of fixed length MSL: 감상평에 해당하는 token sequence. Batch 를 만들 수 있도록 고정된 길이로 통일해야 함.
 - 2) attention mask: input token sequence 의 각 token 마다 attention 에 참여할지 말지를 구분해 주어야 함
 - 3) target label: input token sequence 마다 정답 label (index) 하나를 제공함.

한 훈련예제의 구성: 3

input token seq: (실제는 번호) attention mask seq:

[CLS]	film	lacked	some	points	that	should		[SEP]	[PAD]	[PAD]	[PAD]	[PAD]	[PAD]
1	1	1	1	1	1	1	•••••	1	0	0	0	0	0

target label:

•	innut coa	에서	무자이	ᅖ	아과 되에	enocial	tokon S	을 넣는다:	
•	mput seq		元づら	뛴	끊딱뀌에	Special	token 🖘	テランケン	

- [CLS], [SEP]
- [SEP] 까지의 토큰들에게는 attention mask 로 1 을 주고,
- 그 뒤의 [PAD] 토큰들에게는 attention mask 로 0 을 준다.
- target label: 1/0

training example list 구축 함수

```
def prepare input tok seq and mask seq from file (filename):
    sentences = []
   target labels = []
   # assume that file is in the program directiony (files are naver sentiment data files).
   with open(filename, "r", encoding="utf-8") as fpr:
       for line in fpr.readlines():
           line splited = line.split('\t') # the result is a list of 3 strings: doc id, sentence, label.
           sent = line splited[1]
           sent = sent[:-1]
                                    #remove newline char
           sentences.append(sent)
           lab str = line splited[0] # the last char is a tab.
           lab idx = int(lab str)
           target labels.append(lab idx)
           i = i+1
           if i % 5000 == 0:
               print("number of lines read from file = ", i)
   # each sentence string in sentences is converted into a list of token ids (indices).
   sentences id = [] # a list of sublists; a sublist is a list of indexes of tokens in a sentence.
   for i, sentence in enumerate (sentences):
        token list = tokenizer.tokenize(sentence)
       token id list = tokenizer.convert tokens to ids(token list)
       sentences id.append(token id list)
       if i % 5000 == 0:
           print("tokenizing sentences i", i)
   # prepare 2 separate lists having input token sequence and attention mask.
   list tok seq = []
   list mask seq = []
```

training example list 구축 함수(계속)

```
# 앞 페이지의 list mask seq 문장과 같은 깊이임.
for k, token list in enumerate (sentences id):
    if k \% 5000 == 0:
        print("Number of reviews (for training examples) processed = ", k)
    tok seq = np.zeros(max seq leng, dtype=np.int ) # this is for one sentence.
    mask seq = np.zeros(max seq leng, dtype=np.int)
    tok seq[0] = 2 \# add idx of [CLS] as first element
    mask seq[0] = 1
    tk leng = len(token list)
    if tk leng > max seq leng - 2:
        tk leng1 = max seq leng - 2
     else:
        tk leng1 = tk leng
    place sep = tk leng1 + 1
    for i in range(tk leng1):
        tok seq[i + 1] = token list[i]
        mask seq[i + 1] = 1
    tok seq[place sep] = 3 # idx of token [SEP]
    \max_{k=0}^{\infty} seq[place sep] = 1
    if place sep < max seq leng - 1:
         for j in range(place sep + 1, max seq leng):
            tok seq[j] = 0 \# add pad.
            mask seq[j] = 0 \# add 0 mask.
    list tok seq.append(tok seq)
    list mask seq.append(mask seq)
list tok seq = np.array(list tok seq, np.int32)
list mask seq = np.array(list mask seq, np.int32)
target labels = np.array(target labels, np.int32)
 return list tok seq, list mask seq, target labels
```

train, validation, test 데이터 셋 준비

```
list tok seq all
                                all, target labels all =
                                      seq from file("./train data movie reviews imdb.txt")
      prepare
                                      shape[0]
total num exa
                                        ples * 0.8)
num train examples
num val examples = in
                                        es * 0.1)
num test examples = total
                                        - num train examples - num val examples
                                        n val examples
sum train val = num train ex
print("number of examples(total)
                                        validation, test): ", total num examples, num train examples, \
    num val examples, num test ex
                                         target labels train = list tok seq all[:num train examples], \
list tok seq train, list mask seq
                                         eg all[:num
                              list
                                                                 les], target labels all[:num train examples]
list tok seq val, list mask seq v
                                                                 k seq all[num train examples:sum train val], \
                                                               ples:sum train val],
target labels all[num train exam
list tok seq test, list mask
                                              rabels test = list tok seq all[sum train val:], \
                                          q all[sum train val:], target labels all[sum train val:]
train tok = torch.tensor
                                    eq train, dtype=torch.long)
train mask = torch.tens
                                  /k seq train, dtype=torch.long)
train y = torch.tenso
                                bels train, dtype=torch.long)
val tok = torch.
                             ok seq val, dtype=torch.long)
val mask = ta
                             mask seq val, dtype=torch.long)
val y =
                           t labels val, dtype=torch.long)
                       (list tok seq test, dtype=torch.long)
test
                    _nsor(list mask seq test, dtype=torch.long)
test
test
              .censor(target labels test, dtype=torch.long)
```

```
class BERT Arch(nn.Module):
    def init (self, bert):
        super(BERT Arch, self). init ()
        self.bert = bert
        self.dropout = nn.Dropout(0.1)
        self.relu = nn.ReLU()
        self.fc1 = nn.Linear(768, 512)
        self.fc2 = nn.Linear(512, 256)
        self.fc3 = nn.Linear(256, 2)
        self.softmax = nn.LogSoftmax(dim=1)
    def forward(self, sent id, mask):
        outputs = self.bert(input ids=sent id, attention mask=mask)
        cls out = outputs.pooler output → shape: (batch_sz, 768)
        x = self.fcl(cls out)
        x1 = self.relu(x)
        x2 = self.dropout(x1)
        x3 = self.fc2(x2)
        x4 = self.relu(x3)
        x5 = self.dropout(x4)
        x6 = self.fc3(x5)
        x7 = self.softmax(x6)
        return x7
model = BERT Arch(bert)
model = model.to(device)
```

Optimizer, Loss-function 준비

```
optimizer = torch.optim.AdamW(model.parameters(), lr = 1e-5)
loss_fn = nn.NLLLoss()

num_training_batches = len(train_dataloader)
num_val_batches = len(val_dataloader)
print("num of train and validation batches: ", num_training_batches, " , ", num_val_batches)
```

```
best acc = 1.0
epochs = 7
num training batches = len(train dataloader)
num val batches = len(val dataloader)
print("num of train and validation batches: ", num training batches, num val batches)
for epoch in range(epochs):
   # Traning is done for this epoch.
   model.train()
   total_loss, total_accuracy = 0, 0
   for step, batch in enumerate(train_dataloader):
      batch = [r.to(device) for r in batch]
      sent id, mask, labels = batch
      model.zero_grad()
      preds = model(sent_id, mask)
      loss = loss_fn(preds, labels) # "reduce=True" is default.
      total loss = total loss + loss.item()
      loss.backward()
      optimizer.step()
      if step != 0 and step \% 400 == 0:
         print("Epoch:", epoch, " batch:", step, " has finished.")
   avg_loss = total_loss / len(train_dataloader)
   # evaluate model after each epoch
   model.eval()
   hit cnt = 0
   total cnt = 0
   #with torch.no grad():
```

```
with torch.no_grad():
      for step, batch in enumerate(val_dataloader):
        |batch = [r.tc evice) for r in batch]
        tok part, ma. part, y part = batch
        # model prediction
        preds = model(tok rt, mask_part)
        preds label = torch.ar
                               ax(preds, dim=1)
        preds_label = preds_la
                                 l.cpu()
        preds_label = preds_label
                                 l.numpy()
        y_part = y_part.cpu()
        y_part = y_part.nug
        if preds_lab [i] == y_part[i]:
              hit cnt +=1
        total_cnt___len(y_part)
  acc = hit cnt/total cnt
   print("At epoch:", epoch, " avg loss=", avg_loss, " Accuracy = ", acc)
  # save the best model if the model has improved.
  if acc < best acc:
      best acc = acc
      torch.save(model.state_dict(), 'saved_weights.pt')
      print("Model parameters are saved.")
print("Training ends.")
## 여기에 test 단계를 넣어야 한다.
print("Program ends.")
```